ИНФОРМАТИКА · МАШИННОЕ ОБУЧЕНИЕ

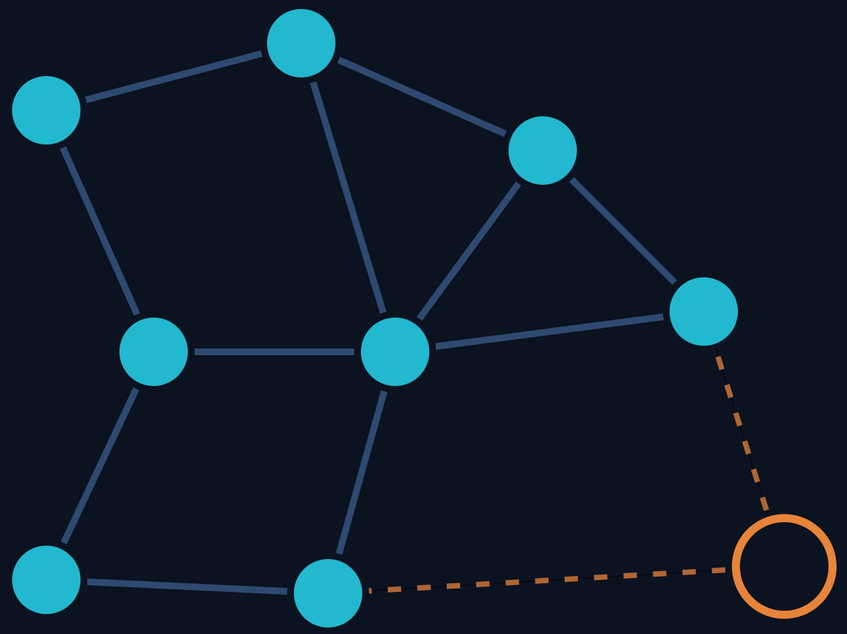
BIO-GINE

Графовая нейросеть, которая предсказывает взаимодействия лекарств — даже для новых препаратов



Маметаев Ерзат

ddi-net.vercel.app



новое лекарство · 0 известных связей

ПРОБЛЕМА 1 · ХОЛОДНЫЙ СТАРТ

У нового лекарства нет соседей

Лекарства — точки, известные взаимодействия — линии. Многие модели предсказывают новые линии по **соседям** лекарства.

Там, где прогноз нужнее всего — для нового лекарства, — такие модели не работают.

ПРОБЛЕМА 2 · УТЕЧКА ДАННЫХ

Модель запоминает, а не обобщает

Случайное деление пар

ОБУЧЕНИЕ

варфарин | аспирин | метформин

ТЕСТ

варфарин | флуконазол

Одно лекарство в обучении и в тесте → модель его узнаёт → результат завышен

Деление по лекарствам — наш подход

ОБУЧЕНИЕ

варфарин | аспирин | метформин

ТЕСТ

флуконазол | кларитромицин

Тестовые лекарства модель не видела → честная проверка на новых

РЕШЕНИЕ · АРХИТЕКТУРА

BIO-GINE: две ветки, одна оценка

ВХОД 1
Молекула как граф атомов

ВХОД 2
Белки и биологические пути

→

GNN · GINE
3 слоя передачи сообщений по атомам

DEEP SETS
множество белков + тип связи

→

СЛИЯНИЕ
вектор лекарства

→

ПАРА A + B
сумма · |разность| · произведение → оценка

Ключевое решение: граф известных взаимодействий не используется — модель работает для лекарства с первого дня

≈1,1 млн параметров · порядок лекарств в паре не важен

ПРОВЕРКА

Честный экзамен: только незнакомые лекарства

255
лекарств только в тесте — модель их не видела

84 690
тестовых пар лекарств

5
независимых запусков обучения

H1–H5
гипотезы записаны до эксперимента

> Отрицательные примеры подобраны так, чтобы модель **не могла угадать по популярности** лекарства. Метрика — AUPRC: качество ранжирования пар.

РЕЗУЛЬТАТ · AUPRC НА НОВЫХ ЛЕКАРСТВАХ

Белки дают прирост — и это не случайность



+0,033

к модели «только молекула» · 95% ДИ 0,028–0,039 · p = 0,0002 с поправкой Холма

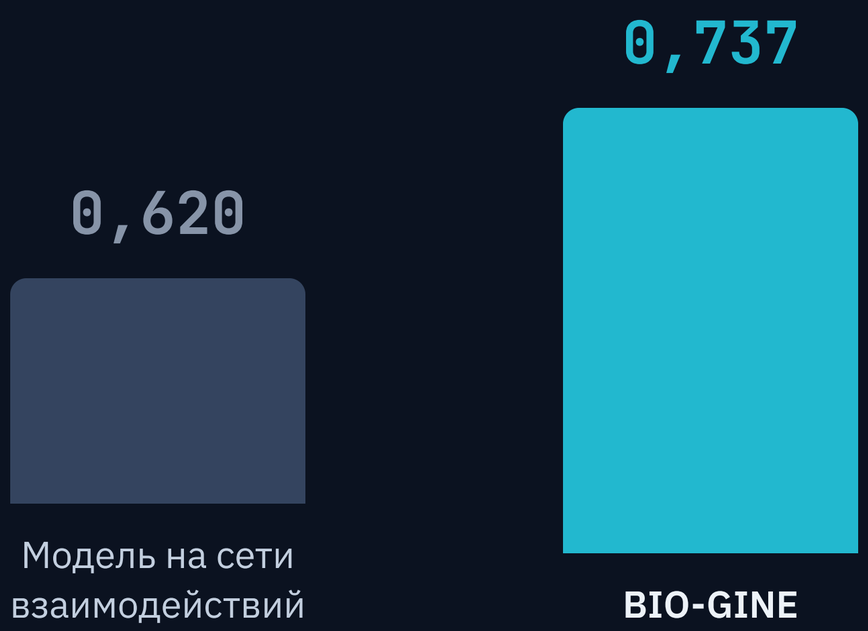
−0,119

если перемешать белки → модель читает биологию, а не известность

САМЫЙ ТРУДНЫЙ СЛУЧАЙ

Оба лекарства в паре новые

7 758 тестовых пар · ни одно из двух лекарств модель не видела



+0,117

Сеть соседей не помогает, когда соседей нет. Молекула и белки есть **у любого** лекарства.

AUPRC · шкала от 0,50 · p = 0,0007

ОТ МОДЕЛИ К ПРОДУКТУ

Нейросеть, которой можно пользоваться

ОБУЧЕНИЕ
PyTorch-модель

→

ЭКСПОРТ
numpy — без PyTorch на сервере

→

КЭШ
1 705 лекарств посчитаны заранее

→

API
FastAPI

→

САЙТ
React

Оценка ≠ диагноз

Оценка модели показана отдельно и не выдаётся за вероятность вреда

Факты — с цитатой

Последствия берутся из официальных инструкций FDA, со ссылкой на текст

Нет данных ≠ безопасно

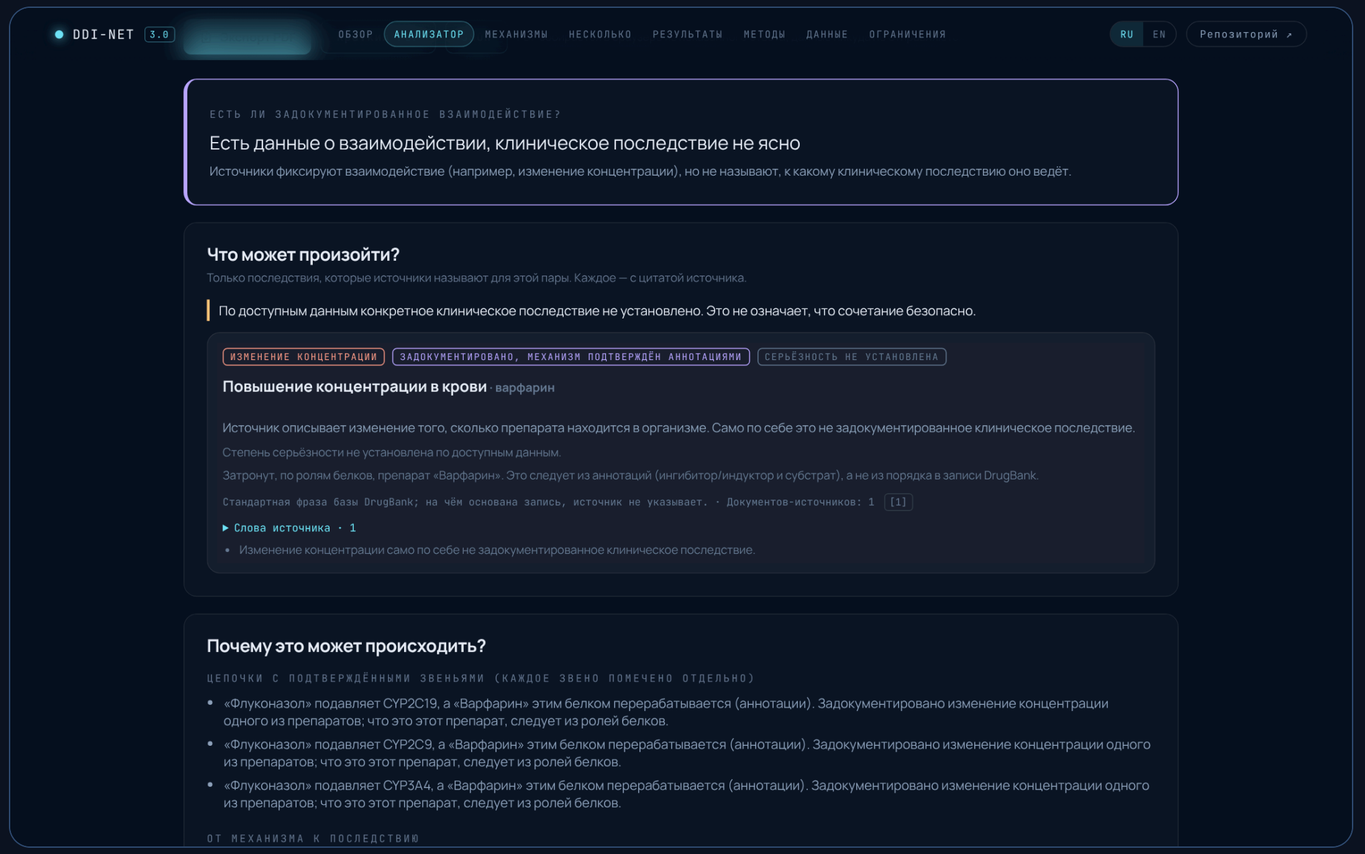
Если данных нет, сайт так и пишет — и не называет сочетание безопасным

ДЕМО

Варфарин + флуконазол

1. **Есть ли взаимодействие** — по данным
2. **Что может произойти** — цитата из инструкции
3. **Оценка BIO-GINE** — отдельно, + отчёт в PDF

Открыть на сайте ↗



ИТОГ

Прогноз с первого дня жизни лекарства

Холодный старт решён

Молекула + белки вместо сети соседей: 0,737 против 0,620 на новых парах

Проверка без утечки

Деление по лекарствам, 5 запусков, гипотезы заранее, контроль с перемешиванием

Работающий продукт

Сайт и API: прогноз отдельно, факты — с цитатой

Спасибо! Вопросы?

ddi-net.vercel.app

github.com/mametaeverzat014-cell/DDI-Net

ЗАПАСНОЙ · МЕТРИКА И ДАННЫЕ

Что такое AUPRC и как делили данные

AUPRC

Площадь под кривой «точность — полнота». Показывает, насколько высоко модель ставит настоящие взаимодействия в своём списке пар.

Отрицательные пары подобраны с той же «популярностью» лекарств, поэтому угадывание по известности даёт только 0,650.

Деление по лекарствам



обучение · валидация · тест (лекарств)

Каждое лекарство только в одной части. Модель выбрана по валидации, тест открыт один раз.

ЗАПАСНОЙ · НОВИЗНА

Что новое, а что — нет

Наш вклад

- Контроль: белки перемешаны между лекарствами с сохранением их количества
- Базовая модель только на числе аннотаций — проверка «а не популярность ли это»
- Гипотезы и поправка Холма заранее; рабочий сайт с цитатами из инструкций

Уже было до нас

- Белки для предсказания взаимодействий — Decagon, 2018
- Холодный старт для новых лекарств — EmerGNN, 2023
- GNN на графе молекулы — GIN / GINE

ЗАПАСНОЙ · ОГРАНИЧЕНИЯ

Честно о слабых местах

Вариант M2 на тесте выше: 0,827

M4 выбрана заранее по валидации среди 96 запусков. Менять выбор после теста — подгонка.

Почему перемешивание даёт 0,692

Молекула остаётся, а количество белков у лекарства сохраняется. Лишь 2,53% связей случайно остались на месте.

H5 не подтвердилась

Поисковая гипотеза: −0,023, p = 0,157. Мы это не скрываем.

> Оценка модели — это ранжирование, а не вероятность вреда. Сайт не даёт персональных советов по лечению.